

UTFPR BCC CAMPO MOURÃO



CLASSIFICADOR DE REGULAMENTAÇÕES na Construção Civil



Autor

Fernando Roberto Delbone

Contexto

- Regras e regulamentações são requisitos essenciais para garantir a segurança, a saúde, o bem-estar, a estabilidade e a usabilidade dos edifícios;
- Transição para processos mais digitais;
- Escritas em formato de texto não estruturado;
- ACCORD-NLP lida com textos regulatórios;
- O sistema pressupõe
- A entrada é sempre uma regra *self-contained*;
- Esse dado é anotado à mão por especialistas.



O Problema



Verificação manual de conformidade é custosa e demorada. Normas técnicas estão em texto natural não estruturado e ambíguo, dificultando a interpretação automatizada.


Ausência de modelos preditivos automáticos para classificação normativa. Triagem manual extensa em bases com dezenas de milhares de sentenças regulatórias.

Perguntas de Pesquisa e Hipóteses

- **Perguntas de Pesquisa**

É possível classificar sentenças como self-contained ou others automaticamente?

Quais características linguísticas são relevantes para a classificação?



- **Hipóteses**

H1: RoBERTa fine-tuned terá desempenho superior

H2: Regras possuem maior frequência de marcadores deônticos (shall, must, should)

H3: Comprimento das sentenças difere estatisticamente e pode ser preditor isolado

Contexto


Classificação binária: regra normativa ou não

Base ACCORD-NLP (construção civil)

Modelos de ML e NLP avaliados

Bases de Dados

- > Definições:
self-contained = regras normativas completas e independentes;
others = sentenças não normativas ou incompletas.
- > Fonte: Base ACCORD-NLP (GitHub) com sentenças do setor da construção civil (Inglaterra e Finlândia).
Volume total: 863 instâncias apenas de regras
- > Fonte: Base ACCORD-NLP (GitHub) com sentenças do setor da construção civil (Inglaterra e Finlândia).
Volume total: 25.867 instâncias entre regras normativas e outras sentenças.
- > Uma base própria do trabalho, junção das sentenças do CODE-ACCORD com as regras
Volume: 5547 instancias.



Pré-processamento e Limpeza dos Dados

Etapa 1 - Remoção de duplicatas e dados sem rótulo

23.276 duplicatas removidas e 266 sentenças sem rótulo excluídas da base ACCORD original.

Da base sintética, 14 excluídas sem rótulo e 2765 duplicados.

Etapa 2 - Rotulação binária


Transformação da variável-alvo em binária: 1 é regra e 0 não é regra.

Etapa 3 - Validação interannotator com Cohen's Kappa

interannotator de 99%, garantindo alta confiabilidade na rotulação e consistência entre anotadores.

Apenas 11 conflitos.


Análise exploratória



Distribuição e Teste Estatístico

Medianas próximas entre classes self-contained e others. Teste Mann-Whitney indica diferença estatisticamente significativa ($p < 0.05$) no comprimento em tokens entre as classes. Apesar da diferença, a sobreposição das distribuições é elevada.

Análise exploratória




Marcadores Deônticos

Isso se dá pela maneira de construção. Na base proposta nesse trabalho, temos como marca maior a anotação dos dados pelos especialistas, utilizando o a base de regras para a construção.

A construção do ACCORD é feita a partir dos dados notados pelo CODE.

Análise exploratória




Quantidade de marcadores

Isso se dá pelo caso do contexto em que está inserido, no caso, `should` é mais uma recomendação, não uma regra explícita. Nas não regras temos a frequência de mais termos sem obrigatoriedade sendo eles water, energy, space, one. termos que não demonstram obrigação.

Agora quando visualizamos as regras, são termos mais específicos, como must, shall.

Mesmo assim eles aparecem em não regras, o que apenas mostra que as regras dependem muito do contexto semântico inserido. Mostrando assim a necessidade de serem anotados dados na mão.

Hipótesis testadas



Poder Preditivo de marcadores e conclusão (H2)

Marcadores shall, must e should são significativamente mais frequentes em sentenças de regras ($p < 0.05$, teste Mann-Whitney), confirmando a hipótese H2.

Conclusão: H2 confirmada. A presença de marcadores deônicos mostra que podem ser um diferencial para a classificação de regras e não regras.



Poder Preditivo e Conclusão (H3)

AUC=0.5 para comprimento como preditor isolado — equivalente a classificação aleatória.

Conclusão: H3 parcialmente confirmada. A diferença existe estatisticamente, mas o comprimento não é útil como preditor isolado para classificação normativa.

Metodologia – Modelos e Representações

Etapa 1: Modelos

- Regressão Logística (baseline)
- Random Forest (padrões não lineares)
- SVM (alta dimensionalidade)


Etapa 2: Representações

- TF-IDF (frequência ponderada)
- TF-IDF + features linguísticas (marcadores deônticos)
- RoBERTa embeddings (CODE-ACCORD fine-tuned)

Etapa 3: Validação


- Validação cruzada estratificada 5-fold
- Métrica: F1-Macro
- Framework DRES para análise de dificuldade
- Seleção dinâmica por instância

Metodologia – Validação e Métricas



Validação Cruzada Estratificada

Validação cruzada estratificada 5-fold para manter proporção entre classes. Métrica principal: F1-Macro, que balanceia precisão e recall entre as classes self-contained e others, garantindo avaliação robusta e confiável.



Framework DRES e Métrica kDN

Framework DRES para análise de dificuldade das instâncias. Métrica k-Disagreeing Neighbors (kDN) identifica sentenças ambíguas. Seleção dinâmica da melhor representação por instância para maximizar desempenho.

Resultados – Performance dos Modelos

Representação	Modelo	ACCORD (Baseline)	Base Sintética	Base Consolidada
TF-IDF	Random Forest	0.843 ± 0.011	0.880 ± 0.010	0.885 ± 0.011
TF-IDF + Features	Random Forest	0.852 ± 0.007	0.883 ± 0.015	0.887 ± 0.011
RoBERTa	Random Forest	0.773 ± 0.011	0.852 ± 0.021	0.861 ± 0.009
DRES	LR + RF + SVM	0.860	0.878	0.877



RoBERTa apresenta desempenho inferior ao esperado (H1 rejeitada). DRES obtém resultados competitivos, mas não supera TF-IDF + RF isoladamente. Características léxicas superam embeddings semânticos neste cenário.

Análise Crítica do RoBERTa

- Alta dimensionalidade (1.024 dims) com poucos dados (<2.500 amostras) prejudica generalização
- TF-IDF com features esparsas: mais interpretável e eficiente no domínio regulatório
- RoBERTa pré-treinado para extração de entidades/relações, não para classificação binária direta
- Embeddings estáticos sem fine-tuning específico limitam a eficácia
- Conclusão: características léxicas superficiais são mais robustas que semânticas profundas neste cenário

Análise de Dificuldade com DRES e kDN


Representação	ACCORD (Baseline)	Base Sintética	Base Consolidada
TF-IDF	0.308	0.298	0.280
TF-IDF + Features	0.260	0.240	0.229
RoBERTa	0.247	0.253	0.259

TF-IDF + Features apresenta menor kDN (menos ambiguidade) nas bases Sintética e Consolidada. A inclusão de marcadores deônticos (shall, must, should) reduz a ambiguidade localmente, confirmando sua relevância discriminante.



Lições Aprendidas – O Que Funcionou

- ✓ TF-IDF + Random Forest: abordagem robusta e generalizável
- ✓ Marcadores deônticos (shall, must, should): principais features discriminantes — H2 confirmada
- ✓ Bases Sintética e Consolidada: melhor balanceamento e desempenho superior ao baseline
- ✓ Validação cruzada estratificada assegurou confiabilidade e reprodutibilidade dos resultados



O Que Não Funcionou

- ✗ RoBERTa embeddings sem fine-tuning específico — H1 rejeitada
- ✗ Comprimento das sentenças: baixo poder preditivo isolado — H3 parcialmente confirmada
- ✗ Features adicionais ao TF-IDF: impacto inconsistente e redundante
- ✗ DRES: ferramenta analítica útil, mas não modelo competitivo em F1-Macro
- ✗ Testes extras: Uso de MLP e representação com WordVec2



Próximos Passos

 Desenvolver fine-tuning específico do RoBERTa para classificação binária direta no domínio regulatório, superando limitações dos embeddings estáticos atuais.

 Expandir a base de dados com rotulação especializada e inclusão de normas internacionais para maior generalização.

 Explorar arquiteturas híbridas e ensembles sofisticados combinando representações léxicas e semânticas para ganhos de desempenho.

 Integrar o sistema ao pipeline ACCORD-NLP para automação da triagem e verificação de conformidade em larga escala.

OBRIGADO PELA ATENÇÃO!
DÚVIDAS?



fernandodelbone@alunos.utfpr.edu.br



github.com/FerDelbo/rule-classification