



Aluno(a)	Fernando Roberto Delbone
Curso	Ciência da Computação
Disciplina	OPT004 - Ciência De Dados
Professor	Prof. Eduardo Pena
Trabalho final: Escolha do Dataset e Definição do Problema	

Introdução

Regras e regulamentações são requisitos essenciais para garantir a segurança, a saúde, o bem-estar, a estabilidade e a usabilidade dos edifícios. De alguns anos para cá, a indústria da construção passa por uma transição para processos mais digitais. No entanto, a verificação do cumprimento e da conformidade dessas normas ainda é feita manualmente por especialistas humanos, um processo histórico que consome uma quantidade significativa de tempo e recursos [2].

Apesar da adoção crescente do meio digital, as normas de construção continuam sendo escritas em formato de texto não estruturado, focado exclusivamente na leitura humana [1]. Para que um sistema automatizado faça essa verificação, é preciso primeiro extrair essas regras textuais e convertê-las em um formato legível por máquinas. Essa conversão é extremamente complexa e esbarra na natureza da linguagem natural, que frequentemente apresenta ambiguidades e estruturas de frases intrincadas [3].

Nesse contexto, o arcabouço *ACCORD-NLP* já implementa funções para lidar com textos regulatórios, tornando possível o aumento de dados, a classificação de entidades e relações, e a extração de informações <https://github.com/accord-project/accord-nlp/tree/main>. Entretanto, o sistema pressupõe que a entrada de texto já seja previamente validada como uma sentença regulatória. Visto isso, falta um modelo preditivo capaz de classificar de forma autônoma se uma sentença avulsa é ou não uma regra. Essa ausência torna a triagem e anotação dos dados um processo obrigatoriamente manual por parte de especialistas, sendo esta a etapa mais custosa do trabalho de [1]. Embora estudos limitados sobre a classificação de sentenças tenham alcançado até 99% de precisão, esses modelos lidam com bases de dados muito pequenas e anotadas à mão, o que encarece e limita a pesquisa. A motivação deste trabalho surge justamente dessa lacuna: ao utilizar a base de dados aumentada desenvolvida nesta pesquisa, espera-se que o modelo alcance uma capacidade de generalização consideravelmente melhor.

Como contribuições, este trabalho visa à criação e disponibilização de um conjunto de dados aberto para a área regulatória, impulsionando o treinamento de novos modelos de aprendizagem de normas. Além de descobrir as características linguísticas de maior peso para criar modelos baseados em inteligência artificial mais interpretáveis, espera-se que os resultados obtidos possam servir como diretrizes práticas para que governos e legisladores redijam futuros códigos de construção já otimizados para a interpretação por máquinas.

Escolha do Dataset

Visto esse problema, foi utilizada a base de dados do *ACCORD-NLP*, disponível em <https://github.com/accord-project/CODE-ACCORD/tree/main>. Nela estão contidas todas as sentenças de documentos regulamentares de construções civis na Inglaterra e Finlândia.

A base final contém apenas regras; entretanto, foi armazenado no processo o que a base chama de ‘others’, ou seja, outros são não regras, os quais não foram utilizados nas ferramentas do *ACCORD-NLP*. Essa base contém 863 regras.

Para que seja possível realizar a tarefa de predizer a classe, foi utilizada uma junção da base com as regras e as demais, ou seja, as outras. Totalizando na nova base 6.939 instâncias.

Formulação do problema

Considerando a lacuna existente na triagem automatizada de textos regulatórios e a necessidade de compreender os padrões que definem uma norma estruturada, a formulação do problema central deste estudo norteia-se pelas seguintes perguntas de pesquisa:

É possível classificar automaticamente sentenças de regulamentações de construção civil como *self-contained* (regra normativa completa) ou *others* (não-regra), com base em características linguísticas e semânticas do texto?

Quais características linguísticas têm maior peso na distinção entre sentenças regulatórias *self-contained* e *others*?

Hipóteses testáveis

Para responder a essas perguntas e orientar a investigação experimental, este trabalho propõe a validação empírica das seguintes hipóteses testáveis:

H1: Modelos de linguagem pré-treinados em domínio regulatório (domain-specific), como RoBERTa fine-tuned no CODE-ACCORD, superam modelos genéricos na classificação binária de sentenças *self-contained* vs. *others*.

H2: Sentenças *self-contained* apresentam frequência significativamente maior de marcadores deônticos (shall, must, should) em comparação com sentenças *others*.

H3: Sentenças *self-contained* possuem distribuição de comprimento (em tokens) estatisticamente diferente das sentenças *others*, sendo essa característica isoladamente um preditor relevante da classe.

Referências

Referências

- [1] Hansi Hettiarachchi, Amna Dridi, Mohamed Medhat Gaber, Pouyan Parsafard, Nicoleta Bocaneala, Katja Breitenfelder, Gonçal Costa, Maria Hedblom, Mihaela Juganaru-Mathieu, Thamer Mecharnia, Sumee Park, He Tan, Abdel-Rahman H. Tawil, and Edlira Vakaj. Code-accord: A corpus of building regulatory data for rule generation towards automatic compliance checking, 2025.
- [2] Mirko Locatelli, Elena Seghezzi, Laura Pellegrini, Lavinia Chiara Tagliabue, and Giuseppe Martino Di Guida. Exploring natural language processing in construction and integration with building information modeling: A scientometric analysis. *Buildings*, 11(12), 2021.
- [3] Zijng Zhang, Ling Ma, and Nicholas Nisbet. Unpacking ambiguity in building requirements to support automated compliance checking. *Journal of Management in Engineering*, 39(5):04023033, 2023.