

Classificador de regulamentações na construção civil

Fernando Roberto Delbone¹, Eduardo H. M. Pena¹

¹Universidade Tecnológica Federal do Paraná (UTFPR)
Departamento de Computação (DACOM)

`fernandodelbone@alunos.utfpr.edu.br, eduardopena@utfpr.edu.br`

1. Introdução

Regras e regulamentações são requisitos essenciais para garantir a segurança, a saúde, o bem-estar, a estabilidade e a usabilidade dos edifícios. De alguns anos para cá, a indústria da construção passa por uma transição para processos mais digitais. No entanto, a verificação do cumprimento e da conformidade dessas normas ainda é feita manualmente por especialistas humanos, um processo histórico que consome uma quantidade significativa de tempo e recursos [Locatelli et al. 2021].

Apesar da adoção crescente do meio digital, as normas de construção continuam sendo escritas em formato de texto não estruturado, focado exclusivamente na leitura humana [Hettiarachchi et al. 2025]. Para que um sistema automatizado faça essa verificação, é preciso primeiro extrair essas regras textuais e convertê-las em um formato legível por máquinas. Essa conversão é extremamente complexa e esbarra na natureza da linguagem natural, que frequentemente apresenta ambiguidades e estruturas de frases intrincadas [Zhang et al. 2023].

Nesse contexto, o arcabouço *ACCORD-NLP* já implementa funções avançadas para lidar com textos regulatórios, tornando possível o aumento de dados, a classificação de entidades e relações, e a extração de informações ¹. Entretanto, o sistema pressupõe que a entrada de texto já seja previamente validada como uma sentença regulatória independente (uma regra *self-contained*), capaz de ser interpretada sem a necessidade de referências externas [Hettiarachchi et al. 2025].

Visto isso, o grande gargalo para a digitalização de ponta a ponta na construção civil é a ausência de um modelo preditivo capaz de classificar, de forma autônoma, se uma sentença avulsa extraída de um documento bruto é ou não uma regra normativa utilizável. Atualmente, métodos de filtragem automática baseados apenas em palavras-chave geram muitos falsos positivos [Hettiarachchi et al. 2026]. Consequentemente, a triagem para isolar as regras válidas do restante do texto comum torna-se um processo obrigatoriamente manual e exaustivo por parte de especialistas [Xue and Zhang 2020]. Em cenários reais, de dezenas de milhares de sentenças em um documento de regulamentação, apenas uma pequena fração representa regras autossuficientes, tornando essa triagem manual a etapa mais custosa e limitante do trabalho de [Hettiarachchi et al. 2025].

Embora estudos limitados sobre a classificação de sentenças tenham alcançado até 99% de precisão, esses modelos lidam com bases de dados muito pequenas e rigorosamente anotadas à mão, o que encarece e restringe a expansão da pesquisa. A motivação deste trabalho surge justamente dessa lacuna crítica: sem um classificador robusto para

¹<https://github.com/accord-project/accord-nlp/tree/main>

triagem inicial, a Verificação Automatizada de Conformidade (ACC) não consegue operar de forma 100% autônoma. Ao utilizar a base de dados aumentada desenvolvida nesta pesquisa, espera-se que o modelo alcance uma capacidade de generalização consideravelmente melhor, eliminando a dependência humana na extração das regras.

Como contribuições, este trabalho visa à criação e disponibilização de um conjunto de dados aberto para a área regulatória, impulsionando o treinamento de novos modelos de aprendizagem de normas. Além de descobrir as características linguísticas de maior peso para criar modelos baseados em inteligência artificial mais interpretáveis, espera-se que os resultados obtidos possam servir como diretrizes práticas para que governos e legisladores redijam futuros códigos de construção já otimizados para a interpretação por máquinas.

2. Definição do problema

Considerando a lacuna existente na classificação automatizada de textos regulatórios e a necessidade de compreender os padrões que definem uma norma estruturada, a formulação do problema central deste estudo norteia-se pelas seguintes perguntas de pesquisa:

É possível classificar automaticamente sentenças de regulamentações de construção civil como *self-contained* (regra normativa completa) ou *others* (não-regra), com base em características linguísticas e semânticas do texto?

Quais características linguísticas têm maior peso na distinção entre sentenças regulatórias *self-contained* e *others*?

2.1. Perguntas de pesquisa

Para responder a essas perguntas e orientar a investigação experimental, este trabalho propõe a validação empírica das seguintes hipóteses testáveis:

H1: Modelos de linguagem pré-treinados em domínio regulatório (domain-specific), como RoBERTa fine-tuned no CODE-ACCORD, superam modelos genéricos na classificação binária de sentenças *self-contained* vs. *others*.

H2: Regras apresentam frequência significativamente maior de marcadores deônticos (shall, must, should) em comparação com sentenças *others*.

H3: Regras possuem distribuição de comprimento (em tokens) estatisticamente diferente das sentenças *others*, sendo essa característica isoladamente um preditor relevante da classe.

3. Análise sobre o problema

Regras '*self-contained*' são sentenças que expressam uma regra normativa completa e contêm todos os detalhes necessários para serem interpretadas de forma independente. Enquanto '*others*' engloba todas as sentenças que não atendem aos rígidos critérios de independência.

Quando analisado o comprimento das sentenças, verificamos que regras e não-regras possuem medianas de *tokens* muito próximas entre si. Apesar de existir diferença estatisticamente significativa pelo teste de *Mann-Whitney* $p < 0.05p$, o AUC obtido ao



Figura 1. Distribuição de tokens por base.

utilizar o comprimento como preditor isolado foi de 0.5, equivalente a uma classificação aleatória. Pode ser acompanhado na Figura 1. Portanto, a quantidade de *tokens* se mostrou uma *feature* irrelevante para a classificação, o que confirma parcialmente H3: a diferença de comprimento existe, mas não possui poder preditivo isolado.

A análise dos marcadores deônticos revelou uma diferença mais expressiva entre as classes. Pelo teste de Mann-Whitney, a frequência de *shall*, *must* e *should* é estatisticamente maior em regras do que em não-regras $p < 0.05$ para todos, suportando H2. Entretanto, esses marcadores também estão presentes em não-regras, o que indica que o contexto semântico é determinante, a presença isolada de um marcador deôntico não é suficiente para classificar uma sentença como regra.

A análise de correlação com a variável alvo confirmou que as features mais discriminantes são *n_deontic*, *has_shall* e *has_should*, alinhadas aos critérios definidos no artigo de referência. Por outro lado, features como *n_tokens*, *n_chars* e *n_commas* apresentaram correlação próxima de zero com *is_rule*, reforçando que características estruturais superficiais não são preditores relevantes para essa tarefa.

Por fim, o Inter-Annotator Agreement calculado pelo Cohen's Kappa entre a ACCORD Oficial e a Base Sintética revelou concordância substancial, com apenas 11 conflitos de classificação nas sentenças em comum. Esses conflitos ocorrem em sentenças genuinamente ambíguas, onde a presença de marcadores deônticos coexiste com referências externas ou co-referências não resolvíveis.

4. Metodologia

Visto esse problema, foi utilizada a base de dados do ACCORD-NLP, disponível em <https://github.com/Accord-Project/CODE-ACCORD/tree/main>. Nela estão contidas todas as sentenças de documentos regulamentares de construções civis na Inglaterra e Finlândia.

A base utilizada no artigo contém apenas 863 regras. Entretanto, o artigo disponi-

biliza, como trabalhos futuros, uma outra base com 25867 instâncias de todas as sentenças retiradas dos artigos. A base contém um identificador, sendo ele o nome do documento que contém as regras, a sentença e os rótulos ‘others’ e ‘self-contained’. Uma limitação na base é que havia diversas regras repetidas, as quais precisaram ser tratadas para a implementação do classificador. Além de não conter todas as sentenças com os rótulos.

Visto essas limitações, esse trabalho utilizou a base disponibilizada pelo ACCORD com os devidos tratamentos. Juntamente com uma base desenvolvida por esse trabalho, a partir das 863 regras e das sentenças das regulamentações Por fim foi utilizada uma junção das sentenças das duas bases para construção de uma só.

4.1. Pré-processamentos

Os pré-processamentos realizados na base do ACCORD foram: remoção de 23.276 sentenças duplicadas e, posteriormente, remoção de 266 sentenças sem rótulo, ficando assim com 2334 instâncias ao todo.

A base desenvolvida nesse trabalho utilizou as anotações do CODE-ACCORD e a base utilizada no artigo [Hettiarachchi et al. 2026], a extração de todas as sentenças e uniu-as em uma única base de dados. Contendo 6077 instâncias, entretanto sofrendo do mesmo problema da base do ACCORD, sentenças duplicadas que foram retiradas. Posteriormente foi gerado um rótulo binário nomeado de ‘*is_rule*’. Os campos que eram ‘others’ e seus derivados, ‘Other’ e ‘other’, foram marcados como 0, e quando *self-contained* ficou como 1. No processo de extração, algumas sentenças eram nulas, as quais forma removidas diretas.

Por fim, haviam 150 sentenças que não haviam rotulo, a fim de preservar elas foi baseado no artigo [Hettiarachchi et al. 2025], que define três critérios simultâneos para uma sentença ser self-contained. Para ser regra, ela precisa passar nos três: Compleitude normativa: expressa uma obrigação, proibição ou permissão completa. Operacionalmente: contém pelo menos um marcador deôntico (shall, must, should, may, must not, shall not). Sem co-referências não resolvíveis: não depende de contexto externo para ser compreendida. Operacionalmente: não começa com pronome sem antecedente claro (It, They, This, These, Such) nem contém the above, the following, as specified. Sem referências externas: não aponta para seções, tabelas, figuras ou documentos externos. Operacionalmente: não contém Section, Table, Figure, Appendix, Clause, Part, see, refer to. Assim a base ficou no final com 2768 instâncias.

A última base foi a partir da união de sentenças distintas em cada uma das bases. Formando assim um *dataset* com 2942 instâncias sendo desenvolvendo coomo uma base full, contendo todas as sentenças anotadas con a a base desenvolvida e a do ACCORD.

A base do ACCORD é considerada mais desafiadora pelo seu balanceamento das classes, sendo 1566 outras e apenas 768 regras. Isso evidencia que o modelo pode ser enviesado, podendo aprender muito bem o que não é uma regra e a partir disso apenas classificar o que não é regra.

A base desenvolvida para esse trabalho conta com um balanço mais justo, com uma proporção de 1180 regras contidas e 1588 outras.

Por fim, quando unido a bases, foram utilizados dados que não continham em uma base ou outra, visto que a base desenvolvida e a do ACCORD contém um IAA, o grau

de concordância entre diferentes ”anotadores”ao classificar os mesmos dados é de 99%, ou seja, algumas sentenças não continham a mesma classificação, sendo regras para uma base para outra. Para esse *dataset*, essas sentenças não foram levadas em conta e retiradas. Uma síntese pode ser vista na Tabela 1.

Tabela 1. Síntese das bases para os modelos desse trabalho.

Base	Fonte	Qtd. Instâncias
Accord (Baseline)	Disponível pelo artigo	2334
Base Sintética de Regras	Construída em cima das 863 regras classificadas	2768
Base Consolidada	junção de sentenças das bases	2942

4.2. Modelagem

Foram utilizados três modelos de aprendizado de máquina para a tarefa de classificação de regras. OS modelos são Regressão Logística, Random Forest e SVM. A justificativa na escolha esta alinhada a literatura sobre classificação de sentenças.

A Regressão Logística foi utilizada como linha de base por sua simplicidade e eficiência em tarefas de classificação textual [Hassan and Mahmood 2018]. O Random Forest foi selecionado por sua capacidade de capturar relações não lineares e padrões complexos presentes na linguagem natural [C 2025]. Já o SVM foi incluído por seu bom desempenho em espaços de alta dimensionalidade gerados por representações textuais como TF-IDF, sendo capaz de encontrar fronteiras de decisão eficazes entre as classes [Le et al. 2026].

Como estamos lidando com texto, é preciso passar de texto para números, visto que esses modelos recebem como entrada apenas números. Para isso, foram avaliadas três técnicas de representação: TF-IDF transforma cada sentença em um vetor numérico com base na frequência das palavras, penalizando termos muito comuns e valorizando os mais específicos [Robertson 2004]. Outra representação usou também o TF-IDF, mas enriquecida com marcadores deônticos como *shall*, *must* e *should* extraídas manualmente[Hettiarachchi et al. 2025]. A terceira representação utilizada foram embeddings gerados pelo modelo ACCORD-NLP/roberta-large-lm, disponibilizado pelos próprios autores do CODE-ACCORD [Hettiarachchi et al. 2026]. e embeddings com Roberta fine-tuning disponibilizado pelo Accord.

Para garantir que os resultados obtidos não dependessem de um único split de dados, todas as combinações de representação e classificador foram avaliadas com validação cruzada estratificada de 5 folds [Kohavi et al. 1995]. Essa abordagem assegura que a proporção entre as classes seja mantida em cada fold, sendo especialmente importante dado o desbalanceamento presente nas bases. Para avaliar os modelos, foi utilizada a métrica F1-Macro, a fim de penalizar modelos enviesados pelo desbalanceamento das classes [Sokolova and Lapalme 2009].

Por fim, foi conduzida uma análise de dificuldade das instâncias utilizando a métrica *k-Disagreeing Neighbors* (kDN) e o framework *Dynamic Representation and Ensemble Selection* (DRES). O kDN mede, para cada sentença, a proporção de seus k

vizinhos mais próximos no espaço vetorial que pertencem a uma classe diferente. Valores próximos de zero indicam instâncias fáceis, onde a vizinhança é homogênea; valores próximos de um indicam instâncias genuinamente ambíguas. O DRES utiliza essa métrica para, dado uma nova sentença, estimar sua dificuldade em cada espaço de representação e selecionar dinamicamente aquela com menor kDN, delegando a classificação aos modelos treinados nessa representação. Essa abordagem não foi concebida como um modelo competitivo em termos de F1-Macro, mas como uma ferramenta de análise para entender em quais regiões do espaço cada representação é mais competente.

5. Resultados

A execução está disponível no GitHub ². Os experimentos foram conduzidos com validação cruzada estratificada de 5 *folds* para garantir que os resultados não dependessem de um *split* específico. Para cada representação, foram avaliados três modelos: Regressão Logística, *Random Forest* e SVM. Os resultados consolidados do melhor modelo por representação e base estão apresentados na Tabela 2.

Tabela 2. F1-Macro por representação e base de dados (CV 5-fold, melhor modelo por configuração)

Representação	Modelo	ACCORD (Baseline)	Base Sintética	Base Consolidada
TF-IDF	Random Forest	0.843 ± 0.011	0.880 ± 0.010	0.885 ± 0.011
TF-IDF + Features	Random Forest	0.852 ± 0.007	0.883 ± 0.015	0.887 ± 0.011
RoBERTa	Random Forest	0.773 ± 0.011	0.852 ± 0.021	0.861 ± 0.009
DRES	LR + RF + SVM	0.860	0.878	0.877

Com o TF-IDF puro, o *Random Forest* obteve o melhor desempenho consistente entre as três bases, alcançando F1-Macro de 0.843 ± 0.011 na ACCORD (Baseline), 0.880 ± 0.010 na Base Sintética e 0.885 ± 0.011 na Base Consolidada. A ACCORD (Baseline) se mostra consistentemente a base mais difícil, o que é esperado dado seu maior desbalanceamento entre classes.

Ao adicionar as *features* linguísticas ao TF-IDF, o impacto foi inconsistente entre as bases. Na Base Consolidada houve uma leve melhora para o *Random Forest* ($0.885 \rightarrow 0.887$), enquanto na ACCORD (Baseline) a Regressão Logística apresentou queda ($0.827 \rightarrow 0.798$). Esse comportamento sugere que as *features* linguísticas extraídas manualmente são em grande parte redundantes com o que o TF-IDF já captura em bigramas como *shall not* e *must be*.

Para a representação com *embeddings* do RoBERTa *fine-tuned* no domínio regulatório, o desempenho ficou abaixo do esperado pela hipótese H1. No baseline, o melhor modelo com RoBERTa atingiu F1-Macro de apenas 0.773, contra 0.843 do TF-IDF com *Random Forest* na mesma base. Na Base Sintética e na Base Consolidada os valores foram melhores, 0.852 e 0.861, respectivamente. Mas ainda inferiores ao TF-IDF. Portanto, **H1 é rejeitada**: o modelo *domain-specific* RoBERTa, quando utilizado apenas como extrator de *embeddings* sem *fine-tuning* para a tarefa de classificação, não supera representações baseadas em frequência de palavras para esse domínio.

²<https://github.com/FerDelbo/rule-classification>

Uma justificativa para esse resultado está no tamanho das bases. O RoBERTa gera vetores de 1.024 dimensões, e separar essas dimensões com menos de 2.500 amostras de treino é uma tarefa estatisticamente difícil para classificadores lineares e baseados em árvores. O TF-IDF, com 5.000 *features* esparsas mas altamente interpretáveis no domínio regulatório, generaliza melhor nesse cenário de dados reduzidos. Isso está alinhado com a literatura, que mostra que modelos de linguagem pré-treinados tendem a superar representações clássicas apenas quando os dados de *fine-tuning* são suficientemente grandes [Devlin et al. 2019].

Por fim, o DRES foi avaliado como uma abordagem de análise da dificuldade das instâncias, não como um modelo competitivo em termos de performance bruta. O kDN médio no treino revelou que o espaço do TF-IDF + *Features* é ligeiramente mais limpo na Base Sintética (kDN de 0.240) e na Base Consolidada (kDN de 0.229), enquanto o RoBERTa apresentou o menor kDN na ACCORD (Baseline) (0.247), conforme apresentado na Tabela 3. Isso demonstra que as representações capturam regiões distintas do problema — cada uma sendo mais competente em determinadas instâncias. O DRES recuperou F1-Macro de 0.860 na ACCORD (Baseline), superando o RoBERTa isolado (0.773), ao selecionar dinamicamente a representação mais adequada para cada sentença. Ainda assim, o DRES não supera o TF-IDF + *Random Forest* em nenhuma das bases, indicando que a seleção dinâmica não compensa a vantagem léxica do TF-IDF para esse domínio específico.

Tabela 3. kDN médio por representação e base de dados

Representação	ACCORD (Baseline)	Base Sintética	Base Consolidada
TF-IDF	0.308	0.298	0.280
TF-IDF + Features	0.260	0.240	0.229
RoBERTa	0.247	0.253	0.259

6. Discussão e trabalhos futuros

Os resultados indicam que a tarefa de classificação de sentenças regulatórias é viável com múltiplas abordagens, respondendo positivamente à Pergunta de Pesquisa 1. Entretanto, a margem entre o melhor e o pior resultado dentro de cada base é relativamente pequena, sugerindo que o fator limitante não é o algoritmo escolhido, mas sim a quantidade e a qualidade dos dados disponíveis.

Nesse sentido, o baseline foi o que obteve a maior variação de F1-Macro. Contudo, com um desvio padrão menor comparado às demais. As bases desenvolvidas para esse trabalho, obtiveram melhores resultados; entretanto, isso se dá por conta do desbalanceamento entre as classes. As bases desenvolvidas são balanceadas com quantidade de regras *self-contained*. Diferente do que ocorre na base do ACCORD.

A rejeição de H1 merece atenção especial. O modelo RoBERTa *fine-tuned* trabalha em cima de sentenças regulatórias, mas para outro caminho, no sentido de *Entity Extraction/Classification* (NER) e *Relation Extraction/Classification* (re). Esse resultado acaba por evidenciar que a utilização de *embeddings* estáticos, sem o ajuste fino direto para a tarefa de classificação binária, gerados por um modelo de grande porte, se mostra ineficiente em cenários de dados reduzidos.

Como o RoBERTa gera vetores de alta dimensionalidade (1.024 dimensões), os classificadores de aprendizado de máquina tradicionais enfrentam dificuldades estatísticas para encontrar fronteiras de decisão claras com menos de 2.500 amostras de treino. Em contrapartida, as representações clássicas baseadas em frequência de termos, como o TF-IDF, conseguem extrair características esparsas, porém altamente interpretáveis e específicas do domínio regulatório (como os bigramas deônticos). Portanto, os resultados demonstram que, para o domínio de normas da construção civil, as características léxicas superficiais são preditores mais robustos e generalizáveis do que as representações semânticas profundas extraídas de modelos pré-treinados generalistas.

O DRES contribuiu para conseguir entender que, mesmo que os resultados TF-IDF com *features* não fossem tão altos quanto TF-IDF puro, o espaço é mais limpo na Base Sintética e na Base Consolidada. Isso mostra, junto com as hipóteses que a inclusão dos marcadores deônticos e das regras de completude normativa reconstrói a estrutura geométrica do problema, reduzindo a ambiguidade na vizinhança das sentenças. Dessa forma, organizou melhor a geometria do espaço, o que beneficiou modelos não-lineares. No entanto, por introduzir redundância de dados e problemas de escala para modelos estritamente lineares, o ganho médio geral acabou sendo mascarado por essas quedas isoladas no classificador linear.

6.1. Trabalhos Futuros

Para trabalhos futuros, é esperado que seja desenvolvido um próprio *fine-tuning* com o modelo RoBERTa para geração de *embeddings* para classificação de sentenças. Neste trabalho, o modelo foi utilizado com ênfase para *Entity Extraction* e *Relation Extraction*, sendo adaptado ao nosso problema.

Por último, é expandir a base de dados, passando por uma classificação de especialistas a fim de gerar melhores dados para o modelo e trazer documentos regulatórios de outros países, analisando o aspecto da linguagem.

Referências

- C, A. K. (2025). Towards eco-friendly cybersecurity: Machine learning-based anomaly detection with carbon and energy metrics. *International Journal of Applied Mathematics*, 38(9s):765–788.
- Devlin, J., Chang, M.-W., Lee, K., and Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. In Burstein, J., Doran, C., and Solorio, T., editors, *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, pages 4171–4186, Minneapolis, Minnesota. Association for Computational Linguistics.
- Hassan, A. and Mahmood, A. (2018). Convolutional recurrent deep learning model for sentence classification. *IEEE Access*, 6:13949–13957.
- Hettiarachchi, H., Dridi, A., Gaber, M. M., Parsafard, P., Bocaneala, N., Breitenfelder, K., Costa, G., Hedblom, M., Juganaru-Mathieu, M., Mecharnia, T., Park, S., Tan, H., Tawil, A.-R. H., and Vakaj, E. (2025). Code-acord: A corpus of building regulatory data for rule generation towards automatic compliance checking.

- Hettiarachchi, H., Gaber, M. M., Parsafard, P., and Vakaj, E. (2026). SNOWTEC: Synthetic natural language oversampling with transformer-based information extraction for automated compliance checking. *Machine Learning with Applications*, 24:100911.
- Kohavi, R. et al. (1995). A study of cross-validation and bootstrap for accuracy estimation and model selection. In *Ijcai*, volume 14, pages 1137–1145. Montreal, Canada.
- Le, V., Tran, T., and Le, T. (2026). Tinyml-driven cybersecurity for autonomous spacecraft: Latency-accuracy analysis for sparta rf and cyber threat detection.
- Locatelli, M., Seghezzi, E., Pellegrini, L., Tagliabue, L. C., and Di Giuda, G. M. (2021). Exploring natural language processing in construction and integration with building information modeling: A scientometric analysis. *Buildings*, 11(12).
- Robertson, S. (2004). Understanding inverse document frequency: On theoretical arguments for idf. *Journal of Documentation - J DOC*, 60:503–520.
- Sokolova, M. and Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information Processing Management*, 45:427–437.
- Xue, X. and Zhang, J. (2020). Building codes part-of-speech tagging performance improvement by error-driven transformational rules. *Journal of Computing in Civil Engineering*, 34(5):04020035.
- Zhang, Z., Ma, L., and Nisbet, N. (2023). Unpacking ambiguity in building requirements to support automated compliance checking. *Journal of Management in Engineering*, 39(5):04023033.